

Predicción del número de divorcios departamentales en Guatemala mediante regresión binomial negativa: relación con la violencia intrafamiliar (2022)

Autores:

Mario Fernando Rocha, Luis Pedro Lira, Juan Francisco Martínez, Joel Antonio Jaquez López, Luis Gilberto González Marroquín.

Departamento de Ciencias de la Computación, Facultad de Ingeniería, Universidad del Valle de Guatemala, Ciudad de Guatemala, Guatemala.

Resumen:

Este artículo analiza la relación entre la violencia intrafamiliar y el número de divorcios registrados a nivel departamental en Guatemala durante el año 2022. Para ello, se utilizaron datos oficiales del Instituto Nacional de Estadística, específicamente registros de violencia intrafamiliar y divorcios. Los datos fueron limpiados, transformados y agregados por departamento, obteniendo una base final de 22 observaciones, una por cada departamento del país.

El objetivo principal del estudio fue evaluar si los casos registrados de violencia intrafamiliar aportan información útil para explicar o predecir la cantidad de divorcios departamentales. Debido a que la variable de respuesta corresponde a un conteo y presenta sobredispersión, se compararon distintos modelos, incluyendo Regresión Binomial Negativa, Regresión Poisson, Random Forest y XGBoost. La validación se realizó mediante Leave-One-Out Cross Validation, adecuada para muestras pequeñas.

Los resultados muestran que la Regresión Binomial Negativa fue el modelo más apropiado, ya que respeta mejor la estructura estadística de los datos. Además, se encontró una asociación positiva entre violencia intrafamiliar registrada y divorcios, aunque esta relación debe interpretarse con cautela por el tamaño reducido de la muestra y la falta de significancia estadística convencional. El estudio también identifica diferencias estructurales importantes, especialmente en el departamento de Guatemala y Alta Verapaz.

Palabras clave / Keywords:

Palabras clave: violencia intrafamiliar, divorcios, regresión binomial negativa, datos de conteo, minería de datos, Guatemala.

Keywords: domestic violence, divorce, negative binomial regression, count data, data mining, Guatemala.

Introducción:

La violencia intrafamiliar y el divorcio son fenómenos sociales que afectan directamente la estructura familiar y reflejan distintas condiciones sociales, culturales e institucionales dentro de un país. En Guatemala, ambos fenómenos son registrados oficialmente por el Instituto Nacional de Estadística, lo que permite analizarlos desde una perspectiva cuantitativa. Sin embargo, aunque pueden estar relacionados, no necesariamente se comportan de la misma manera en todos los departamentos, ya que factores como la urbanización, el acceso a servicios legales, la concentración poblacional y el subregistro pueden modificar la forma en que estos eventos aparecen en los datos oficiales.

Marco teórico:

Violencia intrafamiliar y divorcio en Guatemala

La violencia intrafamiliar constituye un problema social de alta relevancia en Guatemala, regulado legalmente por la Ley para Prevenir, Sancionar y Erradicar la Violencia Intrafamiliar (Decreto 97-1996). El INE sistematiza anualmente los registros de casos denunciados, generando los microdatos utilizados en este estudio (INE, 2022). Bott et al. (2021) documentaron que entre el 63% y el 76% de las mujeres en América Latina han experimentado algún episodio de violencia de género en su vida, lo que sitúa a Guatemala dentro de un contexto regional de alta prevalencia. Según el Censo 2018 (INE, 2018), el país presenta importantes diferencias territoriales en urbanización, composición étnica y acceso a servicios, factores que condicionan tanto el registro de violencia como la formalización de divorcios en cada departamento. El divorcio, por su parte, requiere en Guatemala de un proceso judicial formal, lo que introduce una barrera institucional relevante: no todos los hogares con conflictos terminan en una disolución legal registrada, especialmente en departamentos con menor acceso a juzgados de familia. Esta brecha entre conflictividad real y registro formal es un fenómeno documentado en la región (García-Mora et al., 2023) y es parte de lo que el modelo intenta capturar.

Modelos de regresión para datos de conteo

Cuando la variable respuesta representa el número de veces que ocurre un evento en una unidad de observación, se trata de un dato de conteo. El modelo estadístico estándar para este tipo de datos es la Regresión de Poisson, que asume que la varianza es igual a la media, condición conocida como equidispersión. Cuando los datos presentan varianza sustancialmente mayor que la media existe sobredispersión, y el modelo de Poisson produce errores estándar artificialmente pequeños, inflando la significancia estadística de los coeficientes. La solución estadística estándar es la Regresión Binomial Negativa, que incorpora un parámetro adicional θ para absorber la variabilidad no explicada por la media

(Miah et al., 2024). En este estudio, la razón varianza/media de los divorcios departamentales fue de 949, lo que invalida empíricamente el uso de Poisson como modelo principal.

Algoritmos de aprendizaje automático para fenómenos sociales

La literatura reciente ha explorado el uso de métodos de ensamble para predecir fenómenos sociales a partir de variables sociodemográficas agregadas. Faraji et al. (2023) demostraron que XGBoost captura relaciones no lineales entre indicadores territoriales con mayor flexibilidad que los modelos lineales tradicionales, usando el objetivo count:poisson para respetar la naturaleza discreta de la variable respuesta. Random Forest, por su parte, aporta importancia de variables por permutación, lo que permite identificar qué predictores contribuyen más a la predicción sin asumir linealidad. Arévalo et al. (2024) validaron el uso de Random Forest específicamente en el contexto guatemalteco con datos del INE, en un análisis de formación y disolución de matrimonios con limitaciones de datos similares a las de este estudio.

Heterogeneidad territorial

Diversos estudios enfatizan que los fenómenos demográficos no son uniformes en el territorio. Vanslebrouck y Neels (2025) encontraron que el efecto de predictores como el desempleo sobre el divorcio varía significativamente entre regiones con distinto acceso institucional. Peña y Gómez (2021) documentaron para Colombia que las variables socioeconómicas modifican la probabilidad de separación legal, y que el subregistro es sistemáticamente mayor en zonas rurales. Ambos hallazgos son directamente aplicables al contexto guatemalteco, donde la heterogeneidad entre el departamento capital y el interior del país es estructural y no puede ignorarse en el modelado.

-Este artículo tiene como objetivo general analizar la relación entre los casos registrados de violencia intrafamiliar y el número de divorcios departamentales en Guatemala durante el año 2022, utilizando técnicas de minería de datos y modelos de regresión para datos de conteo. Para ello, se integran y procesan registros oficiales del INE, se agregan los datos a nivel departamental y se construyen variables que permiten comparar el comportamiento de los 22 departamentos del país.

De manera específica, el estudio busca cumplir con cuatro objetivos:

1. Construir una base de datos departamental a partir de los registros del INE (2022) mediante procesamiento en R, para disponer de una base analítica válida.
2. Analizar la distribución departamental de divorcios mediante EDA y métricas de influencia para caracterizar la heterogeneidad territorial.

3. Evaluar la asociación entre violencia intrafamiliar y divorcios departamentales mediante modelos de regresión para datos de conteo, para determinar el impacto sobre la variable respuesta.
4. Comparar el desempeño predictivo de cuatro algoritmos bajo la validación LOOCV, para seleccionar el modelo con mejor balance entre ajuste estadístico, interpretabilidad y parsimonia.

Dado que la variable de respuesta corresponde a un conteo de divorcios y presenta sobredispersión, el análisis presta especial atención a la validez estadística de los modelos utilizados. Por esta razón, la Regresión Binomial Negativa se considera como el modelo principal, mientras que los demás algoritmos se emplean como referencias o herramientas de comparación. Con esto, el artículo no busca demostrar causalidad directa entre violencia intrafamiliar y divorcios, sino identificar patrones departamentales y evaluar si existe una asociación estadística útil para comprender mejor la relación entre ambos fenómenos.

Materiales y métodos:

Fuentes de datos:

Se utilizaron dos conjuntos de datos oficiales del Instituto Nacional de Estadística de Guatemala (INE) correspondientes al año 2022: el registro de violencia intrafamiliar y el registro de divorcios. Los archivos originales se encontraban en formato SPSS (.sav), uno por año, abarcando el período 2012–2022, y fueron convertidos a .csv para su procesamiento en R. Se filtró únicamente el año 2022 para garantizar un análisis de corte transversal limpio, donde cada departamento representa una observación bajo condiciones temporales homogéneas. El dataset de violencia contiene más de 100,000 registros individuales de casos denunciados, con variables como el departamento del hecho, el sexo y edad de la víctima, el área (urbana o rural), el estado civil y el número de hijos. El dataset de divorcios contiene 9,945 registros de disoluciones matrimoniales formales, incluyendo el departamento de ocurrencia y características sociodemográficas de los cónyuges.

Descripción de datos y EDA

Ambos conjuntos fueron combinados a nivel departamental, resultando en 22 observaciones, una por cada departamento del país.

El análisis exploratorio de la variable respuesta reveló una distribución fuertemente asimétrica. La mediana de divorcios por departamento fue de 300 casos, mientras que la media alcanzó 452, indicando que unos pocos departamentos con valores altos están jalando el promedio hacia arriba. El departamento de Guatemala registró 3,295 divorcios, entre seis y ocho veces más que el segundo departamento con mayor volumen. Este comportamiento se

confirmó mediante z-score: el departamento de Guatemala presentó un valor extremadamente superior al resto, confirmando su condición de outlier estructural.

El análisis de correlación entre las variables mostró que la correlación de Pearson entre violencia total y divorcios por departamento fue de $r = 0.82$, una asociación positiva fuerte. Sin embargo, esta correlación es sensible a la presencia del departamento de Guatemala: al excluirlo del cálculo, la correlación disminuye considerablemente, lo que indica que parte de la asociación observada está impulsada por el volumen poblacional de la capital y no exclusivamente por una relación entre los fenómenos.

Respecto a las variables predictoras, se evaluaron seis covariables derivadas de los microdatos de violencia: total de casos, edad promedio de la víctima, número promedio de hijos, proporción de mujeres víctimas, proporción de casos en área urbana y proporción de víctimas casadas. La variable hijos_prom fue descartada por presentar correlación prácticamente nula con la variable respuesta ($r = 0.095$). Las demás variables mostraron correlaciones moderadas, con casos de violencia total como el predictor más asociado con el número de divorcios.

El análisis exploratorio también confirmó que el 88.5% de las víctimas de violencia intrafamiliar son mujeres, con una mediana de edad de 31 años. El 86.3% tiene al menos un hijo, y el 57% de los casos ocurrió en área urbana. Estos patrones son consistentes con la literatura sobre violencia doméstica en contextos latinoamericanos y respaldan la selección de variables sociodemográficas como predictores del modelo.

Preprocesamiento:

Se aplicaron cinco transformaciones antes de ajustar cualquier modelo.

- **Recodificación de valores especiales:** El INE usa los códigos 99 y 999 para representar información no registrada. Estos fueron convertidos a NA para evitar que distorsionaran los cálculos. Sin esta corrección, por ejemplo, una víctima con edad = 999 habría inflado el promedio de edad del departamento.
- **Exclusión del código departamental 99:** Los registros sin departamento asignado no pueden ubicarse geográficamente, por lo que se eliminaron del análisis.
- **Agregación departamental:** Los microdatos individuales se agruparon por departamento, resultando en 22 observaciones, es decir una por departamento, con las siguientes variables: total de casos de violencia, edad promedio de la víctima, proporción de casos en área urbana y total de divorcios.
- **Estandarización z-score:** Las variables numéricas predictoras se transformaron a media = 0 y desviación estándar = 1. Esto fue necesario porque operan en escalas muy distintas, es decir que violencia_total varía decenas de miles mientras que porc_urbano

varía entre 0 y 100. Sin estandarizar, el modelo daría más peso artificialmente a las variables con números más grandes.

- **Variable dummy** es `_capital`: El análisis exploratorio identificó al departamento de Guatemala como un caso estructuralmente diferente y es que su volumen de divorcios es entre seis y ocho veces superior al resto. Se creó una variable binaria que vale 1 para ese departamento y 0 para los demás, permitiendo que el modelo capture esa diferencia sin eliminar la observación.

Estrategia de validación:

Con solo 22 observaciones, una división tradicional 80/20 hubiera dejado en apenas 4 departamentos para prueba, lo cual es demasiado poco para confiar en los resultados. Por eso se utilizó validación cruzada Leave-One-Out (LOOCV) donde en cada iteración el modelo se entrena con 21 departamentos y predice el restante, repitiendo 22 veces hasta que cada departamento fue evaluado exactamente una vez. Las métricas finales se calculan promediando los errores de las 22 iteraciones.

Algoritmos implementados:

Se compararon cuatro algoritmos con roles distintos dentro del análisis:

- **Regresión Binomial Negativa:** se eligió como modelo principal por tres razones. Primero, está diseñada específicamente para datos de conteo con sobredispersión, que es exactamente la condición que presentan los divorcios departamentales con una razón varianza/media de 949. Segundo, tiene respaldo directo en la literatura: Miah et al. (2024) demostraron su superioridad sobre Poisson para modelar conteos departamentales de divorcios. Tercero, con $n = 22$ observaciones, su parsimonia la hace menos propensa al sobreajuste que los modelos de ensamble.
- **Regresión Poisson:** se incluyó como referencia estadística, no como candidata al modelo final. Su propósito fue demostrar empíricamente el costo de ignorar la sobredispersión: la diferencia de AIC entre ambos modelos base fue de más de 1,378 unidades, lo que cuantifica el costo estadístico de violar el supuesto de equidispersión.
- **Random Forest:** se incorporó como modelo de apoyo porque permite detectar relaciones no lineales entre predictores y aporta importancia de variables por permutación, complementando el análisis sin reemplazar al modelo estadístico principal. Arévalo et al. (2024) validaron su uso en el contexto guatemalteco con datos del INE en un problema de características similares. Al-Rashidi et al. (2024) y Villar et al. (2023) también documentaron su capacidad predictiva en problemas de divorcio con variables sociodemográficas.

- **XGBoost:** se incluyó como predictivo para contrastar el enfoque estadístico frente a un método de aprendizaje automático más flexible. Se implementó con el objetivo count:poisson para respetar la naturaleza discreta y no negativa de la variable respuesta. Faraji et al. (2023) validaron esta configuración para predecir fenómenos sociales con variables territoriales similares a las de este estudio. A pesar de obtener un MAE ligeramente menor bajo LOOCV (272.9 vs 290.2), XGBoost no fue seleccionado como modelo principal porque con $n = 22$ los modelos de ensamble tienen mayor riesgo de memorizar los datos de entrenamiento que de aprender patrones generalizables, y porque no permite interpretar directamente el efecto de cada predictor sobre la variable respuesta.

Resultados:

Variable de respuesta:

Los 22 departamentos de Guatemala registraron en 2022 un total de divorcios que osciló entre 137 y 3,295 casos. La mediana fue de 300 divorcios por departamento, mientras que la media alcanzó 452, evidenciando una distribución asimétrica positiva. La razón varianza/media fue de 949, confirmando sobre dispersión severa.

Análisis de influencia:

El análisis de distancia de Cook identificó a Alta Verapaz (código 16) como la observación de mayor afluencia sobre los coeficientes del modelo, con una distancia de 3.881, muy por encima del umbral estándar de $4/n = 0.182$. Este departamento registró más de 42,000 casos de violencia intrafamiliar pero apenas 1,600 divorcios, generando la proporción más inusual del conjunto de datos. El departamento de Guatemala no apareció como influyente porque la variable dummy es_capital ya lo identifica como un caso aparte, absorbiendo su efecto sin distorsionar los demás coeficientes.

Comparación de modelos:

Se evaluaron cuatro variantes de cada algoritmo bajo LOOCV. El Cuadro 1 presenta el mejor modelo de cada algoritmo según MAE.

Cuadro 1. Comparación del mejor modelo por algoritmo bajo validación cruzada Leave-One-Out ($n = 22$ departamentos). *Table 1. Best model comparison by algorithm under Leave-One-Out cross validation ($n = 22$ departments)*

Algoritmo	MAE	RMSE	MAPE(%)	AIC
Reg. Binomial Negativa (NB_1)	290.2	616.7	78.9	289.5
Reg. Poisson (POS_1)	272.9	653.3	60.6	N/A

Random Forest (RF 3)	300.1	658.5	76.0	N/A
XGBoost (XGB 1)	305.3	672.3	79.3	1,668.4

Coefficientes del modelo final:

El modelo ganador fue NB_1 con la siguiente especificación:

$$\log(\hat{\mu}) = \beta_0 + \beta_1 \cdot \text{violencia total}_z + \beta_2 \cdot \text{es capital}$$

El cuadro 2 presenta los coeficientes expresados como razones de tasas de incidencia (IRR)

Cuadro 2. Coeficientes del modelo final (NB1) expresados como IRR con intervalos de confianza al 95%. *Table 2. Final model coefficients (NB_1) as IRR with 95% confidence intervals.*

Variable	IRR	IC 95% Inf.	IC 95% Sup.	p-valor
Intercepto	321.09	270.86	411.73	< 0.001
Violencia total (estand.)	1.318	0.888	1.954	0.140
Es capital (dummy)	3.454	0.629	18.95	0.157

Diagnóstico de residuales:

Los residuales de Pearson del modelo final mostraron que la mayoría de los departamentos se encuentran dentro del rango ± 2 indicando un ajuste razonable. Alta Verapaz presentó el residual más extremo, consistente con su distancia de Cook elevada. El departamento de Guatemala fue predicho con precisión prácticamente perfecta gracias a la variable dummy.

Cuadro 3. Diagnóstico del modelo final (NB1) predicciones, residuales de Pearson y distancia de Cook por departamento, ordenados de mayor a menor influencia. *Table 3. Final model diagnostics (NB_1) predictions, Pearson residuals and Cooks distance by department, sorted by influence.*

Depto.	Divorcios reales	Predichos	Residual Pearson	Cook's D
16	198	526.621	-1.407	3.881
9	794	355.310	2.777	0.248
7	137	268.362	-1.098	0.054
12	565	333.085	1.565	0.050
4	210	358.916	-0.933	0.030
13	450	297.543	1.151	0.027
15	145	313.805	-1.209	0.026
5	497	335.335	1.084	0.025
3	174	332.338	-1.071	0.023
10	485	336.411	0.993	0.021
2	179	303.467	-0.921	0.016
8	201	273.004	-0.592	0.013
19	195	293.000	-0.751	0.013
20	212	273.574	-0.505	0.010
22	402	309.509	0.671	0.008
21	238	272.742	-0.286	0.003
14	314	280.411	0.269	0.002
17	326	299.649	0.198	0.001
6	316	303.662	0.091	0.000
18	286	293.705	-0.059	0.000
11	331	326.321	0.032	0.000
1	3,295	3,295.000	0.000	NaN

Discusión

Selección y justificación del modelo ganador

Los resultados de la comparación bajo LOOCV posicionaron a la Regresión Binomial Negativa (NB_1) como el modelo con mejor balance entre ajuste estadístico y capacidad predictiva. Si bien la Regresión Poisson obtuvo un MAE marginalmente menor (272.9 vs. 290.2), este resultado es engañoso: la razón varianza/media de 949 en la variable respuesta viola directamente el supuesto de equidispersión que Poisson requiere, lo que se reflejó en AIC miles de unidades superiores al de la Binomial Negativa. En presencia de sobredispersión severa, el modelo de Poisson subestima los errores estándar, produciendo inferencias estadísticas no confiables aunque las predicciones puntuales parezcan razonables. Por tanto, NB_1 es el único modelo estadísticamente válido para este problema entre las alternativas paramétricas evaluadas.

Random Forest y XGBoost, aunque conceptualmente capaces de capturar relaciones no lineales, obtuvieron los MAE más altos (300.1 y 305.3 respectivamente). Con $n = 22$ observaciones, estos modelos operan en un régimen donde el riesgo de sobreajuste es elevado incluso con regularización conservadora, y donde la cantidad de datos es insuficiente para explotar su principal ventaja competitiva. Su inclusión en el análisis cumplió un rol de benchmark y exploración, no de reemplazo del modelo principal.

Interpretación de los coeficientes: lo que los datos pueden y no pueden decir

El modelo final NB_1 expresado en razones de tasas de incidencia (IRR) produce resultados que requieren una lectura cuidadosa:

Violencia intrafamiliar total (IRR = 1.318, $p = 0.140$): El coeficiente indica que, manteniendo los demás factores constantes, un incremento de una desviación estándar en los casos de violencia intrafamiliar se asocia con un aumento esperado del 31.8% en el número de divorcios. La dirección del efecto es consistente con la literatura sobre violencia doméstica como factor de ruptura conyugal. Sin embargo, el intervalo de confianza al 95% cruza la unidad (IC: 0.888–1.954) y el p -valor es 0.140, lo que significa que **este efecto no alcanza significancia estadística convencional**. No es correcto interpretar esto como evidencia de que no existe relación; más bien, los datos disponibles son insuficientes para estimarla con la precisión necesaria.

Variable dummy es_capital (IRR = 3.454, $p = 0.157$): El departamento de Guatemala registra en promedio 3.45 veces más divorcios que el resto, controlando por violencia. Nuevamente, el intervalo extremadamente amplio (IC: 0.629–18.95) revela alta incertidumbre en la estimación. Este efecto es estructuralmente real y observable en los datos crudos, pero el modelo no puede cuantificarlo con precisión dado el tamaño muestral.

La causa subyacente de ambas situaciones es la misma: **con $n = 22$ observaciones y al menos tres parámetros que estimar ($\beta_0, \beta_1, \beta_2, \theta$), el modelo opera cerca del límite inferior de lo que permite la inferencia frecuentista confiable.** La potencia estadística para detectar efectos de magnitud moderada es baja, y los intervalos de confianza necesariamente serán amplios.

Alta Verapaz: un caso atípico con explicación estructural

El análisis de distancia de Cook identificó a Alta Verapaz (depto. 16) como la observación de mayor influencia, con una distancia de 3.881, veinte veces por encima del umbral de $4/n = 0.182$. Este departamento registró más de 42,000 casos de violencia intrafamiliar pero apenas 198 divorcios, generando la proporción más inusual del conjunto de datos.

Esta anomalía no es un error de medición sino un fenómeno social documentable: Alta Verapaz es el departamento con mayor proporción de población indígena del país, con comunidades donde el matrimonio civil formal es menos prevalente que las uniones de hecho, y donde el divorcio legal como mecanismo de disolución conyugal tiene menor penetración cultural e institucional. En consecuencia, la violencia intrafamiliar no se traduce en divorcios registrados con la misma frecuencia que en contextos urbanos, no porque la violencia sea menor, sino porque el canal formal de ruptura es diferente. Esto constituye una limitación del indicador utilizado: los divorcios como variable proxy de disolución conyugal captura sistemáticamente menos en contextos rurales e indígenas.

Limitaciones del estudio y rutas de mejora

Este estudio enfrenta tres limitaciones estructurales que deben considerarse al interpretar los resultados:

1. Tamaño muestral fijo por diseño. Guatemala tiene 22 departamentos; no es posible aumentar n sin cambiar la unidad de análisis. Una alternativa válida sería desagregar al nivel municipal (340 unidades), lo que multiplicaría la potencia estadística y permitiría detectar efectos más precisamente. El costo sería mayor heterogeneidad interna y posibles problemas de datos faltantes a nivel municipal.

2. Causalidad vs. asociación. El diseño transversal y agregado de este estudio permite identificar asociaciones entre violencia intrafamiliar y divorcios, pero no establecer causalidad. La dirección del efecto podría ser inversa o estar mediada por terceras variables como nivel socioeconómico, urbanización o acceso a servicios legales. Para avanzar hacia inferencia causal se requeriría un diseño longitudinal con datos de panel departamental.

3. Subregistro diferencial. Tanto los casos de violencia intrafamiliar como los divorcios dependen de denuncia y registro formal. El subregistro no es aleatorio: es sistemáticamente mayor en zonas rurales, indígenas y de menor acceso institucional, lo que introduce sesgo de medición no ignorable. Los coeficientes estimados reflejan la relación entre indicadores registrados, no necesariamente entre los fenómenos reales subyacentes.

Implicación metodológica central

El aporte metodológico más sólido de este trabajo no es la predicción en sí, sino la demostración empírica de que la elección del modelo de regresión para datos de conteo tiene consecuencias concretas. Usar Poisson cuando existe sobredispersión severa produce modelos con AIC artificialmente alto y errores estándar subestimados, lo que llevaría a declarar efectos como significativos cuando no lo son. La Regresión Binomial Negativa, al incorporar el parámetro θ para absorber la variabilidad extra, produce inferencias más conservadoras y estadísticamente honestas, aunque con menor potencia aparente. En contextos de política pública, donde las decisiones se toman con base en estos modelos, esta distinción no es trivial.

Conclusiones

El presente estudio permitió analizar la relación entre violencia intrafamiliar y divorcios a nivel departamental en Guatemala durante el año 2022, utilizando datos oficiales del Instituto Nacional de Estadística y modelos adecuados para una variable de respuesta de conteo. A partir del procesamiento de los registros originales, la agregación departamental y la comparación de distintos algoritmos, se determinó que la Regresión Binomial Negativa fue el modelo más apropiado para representar el problema, no necesariamente por producir el menor error absoluto, sino por respetar mejor la naturaleza estadística de los datos.

La principal conclusión metodológica es que la variable `casos_divorcio` presenta sobredispersión severa, por lo que un modelo Poisson estándar no resulta confiable para la inferencia. Aunque Poisson obtuvo un MAE ligeramente menor en la validación Leave-One-Out, su supuesto de equidispersión se incumple de forma clara. En este contexto, la Regresión Binomial Negativa ofrece una alternativa más sólida, ya que incorpora un parámetro adicional capaz de absorber la variabilidad extra presente en los datos. Por esta razón, el modelo `NB_1` representa el mejor balance entre ajuste, interpretabilidad, parsimonia y validez estadística.

Desde el punto de vista sustantivo, los resultados sugieren una asociación positiva entre los casos registrados de violencia intrafamiliar y el número esperado de divorcios por departamento. El coeficiente de violencia total estandarizada indica que un aumento de una desviación estándar en los casos de violencia se asocia con un incremento esperado del

31.8% en los divorcios. Sin embargo, este efecto no alcanza significancia estadística convencional, por lo que debe interpretarse con cautela. Esto no implica que la relación no exista, sino que con solo 22 observaciones departamentales la estimación no tiene suficiente precisión para sostener una conclusión inferencial fuerte.

El departamento de Guatemala mostró un comportamiento estructuralmente distinto al resto del país. Su volumen de divorcios es considerablemente superior y no puede tratarse como una observación común dentro del modelo. La inclusión de la variable dummy `es_capital` permitió capturar esta diferencia sin eliminar el departamento del análisis. Esto fue importante porque el caso de Guatemala no representa un error de medición, sino una diferencia territorial asociada a mayor concentración poblacional, mayor urbanización y mayor acceso a servicios legales e institucionales.

Alta Verapaz también destacó como un caso especialmente relevante, pero por una razón diferente. Este departamento presentó una relación inusual entre un volumen alto de violencia intrafamiliar registrada y un número relativamente bajo de divorcios. La distancia de Cook lo identificó como la observación más influyente del modelo, lo que evidencia que la violencia registrada no siempre se traduce en divorcios formales con la misma intensidad en todos los contextos. Este resultado sugiere que factores culturales, rurales, institucionales y de acceso a mecanismos legales pueden modificar la relación entre violencia y disolución matrimonial formal.

En síntesis, el proyecto aporta evidencia de una asociación positiva entre la violencia intrafamiliar registrada y los divorcios departamentales, pero también muestra que esta relación está condicionada por diferencias estructurales entre territorios. La Regresión Binomial Negativa permitió modelar de forma más adecuada una respuesta de conteo con sobredispersión, mientras que la validación Leave-One-Out permitió aprovechar al máximo una muestra pequeña. El aporte principal del trabajo no es únicamente predictivo, sino metodológico: evidencia la importancia de elegir modelos coherentes con la estructura de los datos antes de extraer conclusiones sobre fenómenos sociales complejos.

Referencias

Al-Rashidi, A., Al-Rashidi, M., & Al-Zahrani, A. (2024). Divorce prediction using machine learning algorithms in Ha'il region, KSA. PMC / NCBI.

<https://pmc.ncbi.nlm.nih.gov/articles/PMC10766631/>

Arévalo, J., López, M., & Pérez, K. (2024). Análisis de factores socioeconómicos y culturales en la formación y disolución de matrimonios en Guatemala: Un enfoque de minería de datos.

ResearchGate. <https://www.researchgate.net/publication/386540921>

Bott, S., Guedes, A., Ruiz-Celis, A. P., & Mendoza, J. A. (2021). La violencia por parte de la pareja íntima en las Américas: una revisión sistemática y reanálisis de las estimaciones

nacionales de prevalencia. *Revista Panamericana de Salud Pública*, 45, e34.

<https://doi.org/10.26633/RPSP.2021.34>

Faraji, M. R., Wilson, F. A., Bhatt, D. L., & Bhatt, C. (2023). Social vulnerability and initial COVID-19 community spread in the US South: a machine learning approach. *BMJ Health Care Informatics*, 30(1), e100703. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10373713/>

García-Mora, A., Ruiz, C., & Torres, L. (2023). Marriage and divorce during a pandemic: The impact of the COVID-19 pandemic on marital formation and dissolution in Mexico. ResearchGate. <https://www.researchgate.net/publication/369942702>

Instituto Nacional de Estadística —INE— de Guatemala. (2018). XII Censo Nacional de Población y VII de Vivienda. Instituto Nacional de Estadística. <https://censo2018.ine.gob.gt/>

Instituto Nacional de Estadística —INE— de Guatemala. (2022). Violencia intrafamiliar [Dataset oficial]. <https://www.ine.gob.gt/violencia-intrafamiliar/>

Miah, S., Rahman, M., & Islam, T. (2024). Using count regression models to investigate the most important factors affecting divorce rates. *Education Administration: Theory and Practice*, 8(6), 8497–8505. <https://ideas.repec.org/a/ajp/edwast/v8y2024i6p8497-8505id3823.html>

Peña, X., & Gómez, A. (2021). Análisis económico de la violencia doméstica en Colombia, 2012–2019. *Revista de Economía del Rosario*. <https://www.redalyc.org/journal/1002/100254730009/html/>

Sparks, C. (2014). Examining the spatially non-stationary associations between the second demographic transition and infant mortality: A Poisson GWR approach. *PMC / NCBI*. <https://pmc.ncbi.nlm.nih.gov/articles/PMC4224018/>

Vanslebrouck, S., & Neels, K. (2025). The spatial heterogeneity of the determinants of divorce in Belgium (1968–2015). *International Population Conference 2025*. <https://ipc2025.popconf.org/abstracts/250592>

Villar, M., Hernández, D., & Castro, P. (2023). Divorce prediction with machine learning: Insights and LIME explainability. *arXiv*. <https://arxiv.org/pdf/2310.08620>